

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## Desarrollo de un proyecto con Inteligencia Artificial

Este template ha sido diseñado como una guía detallada para el desarrollo de proyectos de inteligencia artificial (IA), siendo su objetivo principal proporcionar una estructura clara y completa que permita a los estudiantes seguir un proceso ordenado y eficiente en los avances de sus proyectos, desde la definición del problema hasta la implementación y evaluación del modelo de inteligencia artificial.

El template está dividido en secciones que abarcan cada una de las etapas clave en el ciclo de desarrollo de un proyecto de IA, incluyendo la definición y contextualización del problema, la recolección y exploración de datos, el modelado y entrenamiento del modelo, la evaluación y disponibilización del mismo como API, así como la planificación, gestión y documentación del proyecto.

Cada sección contiene una descripción de los elementos que se deben considerar en cada etapa, junto con espacios para que completen con la información específica de su proyecto. Además, se incluyen sugerencias y puntos de reflexión que pueden ayudar a mejorar el desarrollo y resultado final.

El objetivo de este documento es facilitar el proceso asegurando que se cubren todos los aspectos necesarios para lograr resultados exitosos y de calidad. Es importante que sigan este template de manera rigurosa y completa, adaptándolo a las particularidades de su proyecto y utilizando la información proporcionada como guía para tomar decisiones informadas en cada etapa del proceso.

Sobre este mismo documento compartido se contempla el versionado para visualizar la evolución a lo largo del cursado como así también la revisión mediante comentarios y sugerencias de cambios que permitan la corrección de forma dinámica entre estudiantes y docentes.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## Índice

Información del Proyecto	3
Definición del Problema	4
Planificación y Gestión de Proyecto	5
Recolección de Datos	6
Ética y Privacidad	7
Exploración de Datos (EDA)	8
Modelado	9
Entrenamiento y Evaluación del Modelo	10
Disponibilización del Modelo como API	11
Futura Integración	12
Monitoreo y Mantenimiento	13
Evaluación del proyecto	14
Próximos pasos y oportunidades de mejora	15
Reflexiones y Agradecimientos	16

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## Información del Proyecto

### ● Nombre del Proyecto:

#### Detección de enfermedades en las plantas mediante imágenes

- Datasets

[kaggle datasets download -d sadmansakibmahi/plant-disease-expert](https://www.kaggle.com/sadmansakibmahi/plant-disease-expert)

[kaggle datasets download -d sujallimje/plant-pathogens](https://www.kaggle.com/sujallimje/plant-pathogens)

### ● Integrantes del equipo 4:

- Díaz, Johanna
- Leo, Sandra
- Pons Toloza, Ma. Florencia
- Villalobos Chaves, María

joha0986@gmail.com  
sandra.e.leo@gmail.com  
ponsmariaflorencia@gmail.com  
maria.villaloboschaves@gmail.com

### ● Representante:

Iremos rotando para no recargar a una persona.

### ● Organización:

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## Definición del Problema

### ● Descripción del problema:

La agricultura enfrenta grandes desafíos debido a la propagación de enfermedades de las plantas, con pérdidas de rendimiento global potencialmente tan altas como el 16%. Estas enfermedades son causadas por patógenos como hongos, bacterias, virus y plagas y afectan a una amplia gama de cultivos, plantas ornamentales y árboles. La identificación temprana y precisa de estas enfermedades es fundamental para tomar medidas de control eficaces y minimizar el impacto en la producción agrícola.

Sin embargo, la detección manual de enfermedades de las plantas es un proceso laborioso y propenso a errores, ya que requiere experiencia y una observación cuidadosa de los síntomas. Además, las condiciones ambientales variables y la diversidad de especies complican la identificación precisa de las enfermedades.

La inteligencia artificial (IA) ofrece una solución prometedora a este problema mediante el desarrollo de modelos de aprendizaje automático capaces de analizar imágenes de plantas de alta resolución y detectar automáticamente síntomas de enfermedades. Estos modelos se pueden entrenar utilizando una amplia gama de conjuntos de datos que incluyen imágenes de una variedad de enfermedades y condiciones de crecimiento, lo que les permite aprender a reconocer patrones y firmas asociadas con cada enfermedad.

El sistema resultante basado en inteligencia artificial proporcionará diagnósticos rápidos, eficientes y convenientes, lo que ayudará a los agricultores a mantener sus cultivos saludables y optimizar sus recursos mediante la identificación precisa de enfermedades.

### ● Contexto del problema:

La agricultura es un pilar fundamental de la economía mundial y de la seguridad alimentaria, ya que proporciona alimentos, fibras y materias primas a millones de personas. Sin embargo, el sector agrícola enfrenta múltiples desafíos, siendo las enfermedades de las plantas una de las más graves. Estas enfermedades, causadas por diversos patógenos, pueden afectar gravemente la salud de los cultivos, causar importantes pérdidas económicas y amenazar el suministro de alimentos.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



En el contexto del cambio climático, los cambios en las condiciones climáticas y la aparición de nuevas cepas de patógenos están aumentando la incidencia y gravedad de las enfermedades de las plantas. Esto hace que la detección temprana y precisa sea más importante que nunca. La agricultura moderna también está bajo presión para aumentar los rendimientos para satisfacer la creciente demanda de alimentos, lo que requiere métodos de manejo de cultivos más eficientes y sostenibles.

En cuanto a la **relevancia de la resolución del problema**, se destacan los siguientes puntos:

1. **Seguridad alimentaria:** la capacidad de detectar y controlar enfermedades de las plantas es fundamental para garantizar un suministro estable de alimentos. Las pérdidas de cultivos pueden provocar escasez de alimentos, precios más altos y, en última instancia, inseguridad alimentaria.
2. **Impacto económico:** Las enfermedades de las plantas pueden causar pérdidas económicas significativas a los agricultores y a la agricultura en su conjunto. Implementar tecnología que mejore la detección de enfermedades puede ayudar a reducir costos y aumentar la rentabilidad.
3. **Sostenibilidad Agrícola:** La agricultura sostenible es fundamental para preservar los recursos naturales y minimizar el impacto ambiental. La detección temprana de enfermedades permite a los agricultores aplicar tratamientos de manera más precisa, reduciendo el uso de pesticidas y otros insumos químicos.
4. **Innovación Tecnológica:** La integración de inteligencia artificial en la agricultura representa una oportunidad para innovar en el sector. Las tecnologías emergentes pueden transformar la forma en que se gestionan los cultivos, mejorando la eficiencia y la efectividad de las prácticas agrícolas.
5. **Accesibilidad de la tecnología y la información:** La relevancia del problema también radica en la necesidad de ofrecer recursos de acceso libre a los agricultores para que tomen decisiones informadas y basadas en datos.

## ● Impacto del problema:

No contar con herramientas que apoyen decisiones para la sanidad de los cultivos, en un formato de detección temprana tiene las siguientes consecuencias:

- **Demora en la Detección Temprana de enfermedades:** Si bien, los agricultores tienen la experiencia necesaria para poder conocer algunas enfermedades, no siempre se tiene la totalidad de la información adecuada para ello, lo que conlleva a que no se puedan tomar decisiones oportunas basadas en información para poder detectar qué tipo de enfermedad afecta al cultivo.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



- **Utilización de Recursos:** si se carece de la información adecuada, los tratamientos a aplicar pueden no ser eficientes ni tampoco sustentables, lo que muchas veces no permite realizar ahorros ni minimizar el impacto ambiental.
- **Disminución de la productividad:** con la detección tardía de enfermedades, los agricultores no pueden mantener la salud de sus cultivos, lo que se traduce en una disminución en la producción y la calidad de los productos agrícolas. Esto puede contribuir a una menor estabilidad económica.
- **Imposibilidad de realizar Agricultura de Precisión:** al no tener datos y análisis para tomar decisiones informadas no se puede mejorar la sostenibilidad y la eficiencia en la producción agrícola.
- **Crecimiento y proyección de los cultivos:** Al no contar con información oportuna los agricultores no pueden proyectar su crecimiento económico, y muchas veces se encuentran solicitando aportes al Estado para poder sostener la actividad.

## ● Alcance:

El alcance del problema relacionado con las enfermedades de las plantas y su detección mediante inteligencia artificial, se puede definir en varios aspectos clave que establecen los límites y las áreas de enfoque de la solución propuesta:

### Especies de Cultivos:

La solución se centrará en un conjunto específico de cultivos agrícolas, que pueden incluir hortalizas, frutas, cereales y plantas ornamentales. No abarcará todas las especies de plantas, ya que cada tipo puede presentar diferentes enfermedades y requerir enfoques específicos.

### Tipos de Enfermedades:

En una primera etapa, la detección se enfocará en un conjunto definido de enfermedades comunes, como aquellas causadas por hongos, bacterias y virus. No se incluirán todas las posibles enfermedades, especialmente aquellas que son raras o menos prevalentes.

### Métodos de Detección:

La solución se basará en técnicas de procesamiento de imágenes y aprendizaje automático para la detección de enfermedades. No se abordarán otros métodos de diagnóstico, como análisis de laboratorio o pruebas químicas.

### Contexto Geográfico y alcance de las validaciones del modelo:

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



El enfoque inicial no se limitará a una región geográfica específica, las pruebas y validaciones del modelo sólo se realizarán con datos de prueba. El alcance final del proyecto está limitado a lo solicitado en el curso.

## Usuarios Finales:

La solución se dirigirá principalmente a agricultores y profesionales del sector agrícola que buscan mejorar la gestión de sus cultivos. No se incluirán otros actores del sector, como investigadores o instituciones académicas, en esta fase inicial.

## Resultados Esperados:

Los resultados se centrarán en la mejora de la detección de enfermedades y la reducción de pérdidas de rendimiento. No se abordarán otros aspectos de la producción agrícola, como la mejora genética de cultivos o el manejo del suelo.

## ● Objetivos del problema:

### Objetivo General

- Desarrollar una solución basada en inteligencia artificial para la detección temprana y precisa de enfermedades en cultivos agrícolas, con el fin de mejorar la gestión de los cultivos y aumentar la productividad agrícola.

### Objetivos Específicos

#### 1. Mejorar la Precisión de Detección:

- Desarrollar modelos de aprendizaje automático que puedan identificar y clasificar enfermedades de las plantas con una alta tasa de precisión, utilizando imágenes de alta resolución de los cultivos.

#### 2. Facilitar la Detección Temprana:

- Implementar un sistema que permita a los agricultores detectar síntomas de enfermedades en etapas tempranas, antes de que se produzcan daños significativos en los cultivos.

#### 3. Optimizar el Uso de Recursos:

- Proporcionar recomendaciones basadas en datos para el tratamiento de enfermedades, permitiendo a los agricultores aplicar insumos y pesticidas de manera más eficiente y solo donde sea necesario.

#### 4. Aumentar la Productividad Agrícola:

- Contribuir a un aumento en el rendimiento de los cultivos mediante la reducción de pérdidas causadas por enfermedades, mejorando así la rentabilidad de los agricultores.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## 5. Fomentar la Educación y Capacitación:

- Desarrollar materiales de capacitación y talleres para educar a los agricultores sobre el uso de la tecnología de detección de enfermedades y la interpretación de los resultados, empoderándolos para tomar decisiones informadas.

## 6. Evaluar el Impacto del modelo:

- Establecer métricas y métodos de evaluación para medir la efectividad de la solución en términos de precisión de detección.

## 7. Promover la Sostenibilidad Agrícola:

- Contribuir a prácticas agrícolas más sostenibles al reducir la dependencia de pesticidas y otros insumos químicos, minimizando el impacto ambiental de la producción agrícola.

## ● Requerimientos y restricciones:

Al abordar el problema de la detección de enfermedades de las plantas mediante inteligencia artificial, es fundamental considerar tanto los requerimientos necesarios para el desarrollo e implementación de la solución como las restricciones que pueden influir en su efectividad. A continuación se enumeran estos aspectos:

### Requerimientos

#### 1. Datos de Entrenamiento:

- Se requiere un conjunto de datos amplio y diverso que incluya imágenes de cultivos sanos y enfermos, con etiquetas que identifiquen las enfermedades específicas. Esto es crucial para entrenar modelos de aprendizaje automático.

#### 2. Infraestructura Tecnológica:

- Se necesita acceso a hardware adecuado (como servidores o computadoras con capacidad de procesamiento gráfico) para entrenar y ejecutar modelos de IA, así como para almacenar y procesar grandes volúmenes de datos.

#### 3. Software de Desarrollo:

- Herramientas y bibliotecas de programación para el desarrollo de modelos de IA, así como software para el procesamiento de imágenes y análisis de datos.

#### 4. Interfaz de Usuario:

- Desarrollo de una interfaz amigable para que los agricultores puedan cargar imágenes de sus cultivos y recibir resultados de detección de enfermedades de manera intuitiva.

#### 5. Capacitación y Soporte:

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



- Programas de capacitación para los agricultores sobre el uso de la tecnología, así como soporte técnico para resolver problemas que puedan surgir durante su implementación.

## 6. Colaboración con Expertos:

- Involucrar a fitopatólogos y agrónomos en el proceso de desarrollo para asegurar que los modelos de IA sean precisos y relevantes para las enfermedades de las plantas en la región.

## Restricciones

### 1. Limitaciones de Datos:

- La disponibilidad de datos de calidad puede ser una restricción, especialmente en regiones donde la documentación de enfermedades de las plantas no es sistemática.

### 2. Condiciones Ambientales:

- Las variaciones en las condiciones climáticas y ambientales pueden afectar la aparición y severidad de las enfermedades, lo que puede complicar la generalización de los modelos de IA.

### 3. Costo de Implementación:

- Los costos asociados con la implementación de la tecnología, incluyendo hardware, software y capacitación, pueden ser una barrera para algunos agricultores, especialmente los de pequeña escala.

### 4. Adopción por Parte de los Agricultores:

- La resistencia al cambio y la falta de familiaridad con la tecnología pueden limitar la adopción de la solución por parte de los agricultores, lo que puede afectar su efectividad.

### 5. Regulaciones y Normativas:

- Las regulaciones locales sobre el uso de pesticidas y tratamientos agrícolas pueden influir en las recomendaciones proporcionadas por la solución, limitando su aplicabilidad.

### 6. Escalabilidad:

- La solución debe ser escalable para adaptarse a diferentes tipos de cultivos y enfermedades, lo que puede requerir ajustes en los modelos y en la infraestructura tecnológica.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## ● Beneficios esperados:

La implementación de soluciones basadas en inteligencia artificial (IA) para la detección de enfermedades de las plantas tiene el potencial de transformar la situación actual de varias maneras:

- **Mejora en la Detección Temprana:** Los modelos de IA pueden analizar imágenes de cultivos y detectar síntomas de enfermedades de manera más rápida y precisa que los métodos tradicionales. Esto permite a los agricultores identificar problemas antes de que se propaguen, facilitando intervenciones oportunas.
- **Optimización de Recursos:** Al permitir un diagnóstico más preciso, la IA puede ayudar a los agricultores a aplicar tratamientos sólo donde son necesarios, reduciendo el uso de pesticidas y otros insumos. Esto no solo ahorra costos, sino que también minimiza el impacto ambiental.
- **Aumento de la productividad:** Con una detección más efectiva de enfermedades, los agricultores pueden mantener la salud de sus cultivos, lo que se traduce en un aumento en la producción y la calidad de los productos agrícolas. Esto puede contribuir a una mayor estabilidad económica para los agricultores.
- **Fomento de la Agricultura de Precisión:** La integración de tecnologías de IA en la agricultura promueve prácticas de agricultura de precisión, que utilizan datos y análisis para tomar decisiones informadas. Esto puede mejorar la sostenibilidad y la eficiencia en la producción agrícola.
- **Capacitación y Empoderamiento:** La adopción de tecnologías basadas en IA también implica la capacitación de agricultores y profesionales en el uso de estas herramientas. Esto no solo mejora sus habilidades, sino que también les empodera para tomar decisiones basadas en datos, mejorando su capacidad para manejar sus cultivos de manera efectiva.

## Planificación y Gestión de Proyecto

### ● Cronograma:

**Duración estimada del proyecto:** 12 semanas.

- Semana 1:
  - Hito: Definición del proyecto y objetivos.
  - Entregable: Documento inicial del proyecto, incluyendo descripción del problema, objetivos generales y específicos.
- Semana 2-3:

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



- Hito: Recolección y análisis de datasets.
- Entregable: Datasets preparados para el preprocesamiento (descargados, descomprimidos y analizados).
- Semana 4-5:
  - Hito: Preprocesamiento de imágenes.
  - Entregable: Imágenes pre procesadas y listas para el entrenamiento del modelo.
- Semana 6-7:
  - Hito: Desarrollo del modelo de IA.
  - Entregable: Arquitectura del modelo definida y primera versión entrenada.
- Semana 8:
  - Hito: Validación y ajuste del modelo.
  - Entregable: Resultados de validación con métricas de rendimiento (precisión, pérdida, etc.).
- Semana 9:
  - Hito: Desarrollo de la interfaz de usuario (opcional).
  - Entregable: Prototipo funcional para que los usuarios puedan cargar imágenes y recibir diagnósticos.
- Semana 10:
  - Hito: Documentación técnica.
  - Entregable: Documentación del código, flujo de trabajo y descripción del modelo desarrollado.
- Semana 11:
  - Hito: Pruebas y validación final.
  - Entregable: Resultados finales del modelo con reporte de precisión y análisis de errores.
- Semana 12:
  - Hito: Presentación del proyecto y entrega final.
  - Entregable: Presentación del proyecto, informe final y entrega del código.

## ● Responsabilidades del equipo:

Dado que estamos en un proyecto educativo, las responsabilidades del equipo se irán definiendo acorde a los hitos que debemos cumplir y las tareas que deben ser realizadas para finalizar cada hito.

Durante el proceso exploratorio hemos dividido al equipo en dos partes, mientras una parte del equipo avanza en el desarrollo y ensayo del código, la otra parte va documentando el trabajo, esta situación será modificada durante el desarrollo del proyecto, según los objetivos que deban cumplirse.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## ● Herramientas de comunicación:

- Whatsapp: Para la comunicación diaria y rápida entre los miembros del equipo.
- Google Drive: Almacenamiento y compartición de documentos y archivos.
- Google Meet/Zoom: Reuniones semanales para el seguimiento de avances y resolución de problemas.
- GitHub/Collab: Para la gestión y entorno de ejecución del código y control de versiones.

## ● Reuniones:

- Reunión de inicio: Primera semana para establecer los objetivos del proyecto y las responsabilidades.
- Reunión semanal: Una vez por semana para revisar el progreso y coordinar las próximas tareas.
- Reuniones extraordinarias: En caso de surgir problemas que requieran resolución inmediata.

## ● Seguimiento y control:

Cada miembro del equipo tendrá asignadas tareas específicas y se hará seguimiento del avance de cada etapa.

Se definirán "sprints" semanales, donde al final de cada uno se revisará el avance y se harán ajustes si es necesario.

### ● Revisión semanal:

- En conjunto se revisará el progreso de cada tarea asignada y se asegurará de que el equipo esté alineado con los objetivos del cronograma.
- Cada miembro del equipo deberá reportar el estado de sus tareas semanalmente en la reunión.

### ● Entregables clave:

- Al final de cada etapa del cronograma, se entregará un reporte parcial o producto intermedio (dataset preprocesado, modelo entrenado, etc.) para asegurar que el proyecto avance conforme a lo planificado.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## ● Riesgos Identificados

1. Insuficiencia de datos de entrenamiento:
  - Riesgo de que los datasets no contengan suficientes imágenes de todas las enfermedades o que las imágenes no tengan la calidad adecuada.
2. Capacidades técnicas limitadas:
  - Riesgo de que el equipo no cuente con el hardware necesario (GPU) para entrenar los modelos de IA a tiempo.
3. Problemas en la coordinación del equipo:
  - Riesgo de que haya retrasos por falta de comunicación o descoordinación entre los miembros del equipo.
4. Sobreajuste del modelo:
  - Riesgo de que el modelo de IA se ajuste demasiado al dataset de entrenamiento y no generalice bien en datos nuevos.
5. Resistencia a la adopción de nuevas tecnologías por parte de los usuarios finales (agricultores):
  - Riesgo de que los usuarios finales no adopten la herramienta por desconocimiento o falta de capacitación.

## ● Plan de mitigación de riesgos:

1. Insuficiencia de datos de entrenamiento:
  - Mitigación: Recolectar datos adicionales de fuentes externas (Kaggle, repositorios públicos) o aplicar técnicas de aumento de datos (data augmentation).
2. Capacidades técnicas limitadas:
  - Mitigación: Utilizar plataformas como Google Colab o AWS, que ofrecen GPUs de forma gratuita o por bajo costo.
3. Problemas en la coordinación del equipo:
  - Mitigación: Establecer reuniones semanales obligatorias y definir roles claros desde el inicio. Utilizar herramientas de gestión de tareas para visualizar el progreso en tiempo real.
4. Sobreajuste del modelo:
  - Mitigación: Implementar validación cruzada y regularización en el modelo, además de pruebas extensivas con datos de validación para verificar la generalización.
5. Resistencia a la adopción de nuevas tecnologías:
  - Mitigación: Ofrecer tutoriales y capacitaciones sobre el uso de la herramienta a los agricultores, presentando ejemplos prácticos y demostraciones.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## Recolección de Datos

### ● Fuente de los datos:

Los datasets se obtienen de Kaggle, específicamente los siguientes conjuntos de datos: Plant Disease Expert Dataset ubicado en [kaggle datasets download -d sadmansakibmahi/plant-disease-expert](https://www.kaggle.com/sadmansakibmahi/plant-disease-expert)

Si bien también estaría disponible el dataset Plant Pathogens Dataset, por razones de tiempo no será utilizado durante esta etapa del proyecto.

### ● Tipo de datos:

Imágenes no estructuradas de hojas y frutos de plantas afectadas por diferentes enfermedades.

### ● Formato de los datos:

Los archivos se encuentran en formato .jpg

### ● Volumen de los datos:

El volumen total de imágenes en los datasets es de 199.665 imágenes.

### ● Calidad de los datos:

Los datos serán evaluados para asegurar su:

- Completitud (todas las enfermedades relevantes están representadas).
- Corrección (imágenes etiquetadas adecuadamente con la enfermedad que representan).
- Homogeneidad de formato (todas las imágenes en formatos uniformes, como .jpg).
- Balance en la cantidad de imágenes por enfermedad para evitar sesgos durante el entrenamiento.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## ● Posibilidad de obtener más datos:

Existe la posibilidad de ampliar el dataset recurriendo a otras fuentes abiertas, como repositorios académicos o comerciales, o aplicando técnicas de *data augmentation* (aumento de datos).

Indicar si existe la posibilidad de obtener más datos a futuro a medida que avance el proyecto.

## ● Posibilidad de validar y corregir datos:

La validación de los datos se podrá realizar en conjunto con expertos fitopatólogos, para asegurar que las etiquetas de las enfermedades son correctas.

## ● Ejemplos de datos:



Imágenes de hojas afectadas por diferentes enfermedades, como:

- Anegamiento en la planta
- Tizón tardío de la papa
- Virus del mosaico del tomate
- Costra de la manzana
- Corazón hueco de patata
- Chancro del tomate
- Podredumbre negra de la manzana
- Araña roja del tomate Araña roja de dos manchas
- Tizón temprano de la patata
- Tizón bacteriano de la hoja en la hoja de arroz

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



- Mancha foliar por septoria del tomate
- Deficiencia de nitrógeno en planta
- Mancha marrón en hoja de arroz
- Mancha objetivo del tomate

Producto	Cantidad de Imágenes
Orange Haunglongbing Citrus greening	52.872
Grape Esca Black Measles	13.284
Soybean healthy	12.216
Grape Black rot	11.328
Grape Leaf blight Isariopsis Leaf Spot	10.332
Tomato Bacterial spot	6.381
Apple Apple scab	6.048
Apple Black rot	5.964
Tomato Late blight	5.727
Tomato Septoria leaf spot	5.313
Tomato Spider mites Two spotted spider mite	5.028
Tomato Target Spot	4.212
Apple healthy	3.948
Common Rust in corn Leaf	3.918
Tomato healthy	3.819
Blueberry healthy	3.606
Pepper bell healthy	3.549
Blight in corn Leaf	3.438
Potato Early blight	3.000
Potato Late blight	3.000
Tomato Early blight	3.000

El 80 % de las imágenes se encuentra en las primeras 5 clases que contiene el dataset.



միմելք:լեճ



միմելք:լեճ



միմելք:լեճ

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



- Enlace a repositorio con los datos:  
[https://drive.google.com/drive/folders/1l9zro3\\_UOJlJpZlzeMY37q5rbOwwJB7O  
?usp=drive\\_link](https://drive.google.com/drive/folders/1l9zro3_UOJlJpZlzeMY37q5rbOwwJB7O?usp=drive_link)

## Ética y Privacidad

### ● Consideraciones éticas:

El proyecto está comprometido con el uso responsable de la inteligencia artificial. En particular, se tendrá cuidado en:

- No reemplazar el trabajo humano de los fitopatólogos, sino complementar su labor.
- Evitar sesgos en el modelo de IA que podrían perjudicar la agricultura en determinadas regiones.
- Asegurar la transparencia en la toma de decisiones automáticas por parte del sistema.

### ● Privacidad de los datos:

Dado que los datos provienen de fuentes abiertas y no contienen información personal, no se requiere aplicar medidas estrictas de privacidad. Sin embargo, se garantizará que los datos recopilados de cualquier fuente nueva sean manejados de acuerdo con las mejores prácticas de protección de datos.

### ● Cumplimiento normativo:

El proyecto se desarrollará bajo las normativas de uso de datos abiertos, cumpliendo con regulaciones como las licencias de datos de Kaggle y asegurando el respeto de los derechos de los productores de datos. Además, en caso de expandirse, se evaluará la necesidad de cumplir con normativas locales de protección de datos agrícolas.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



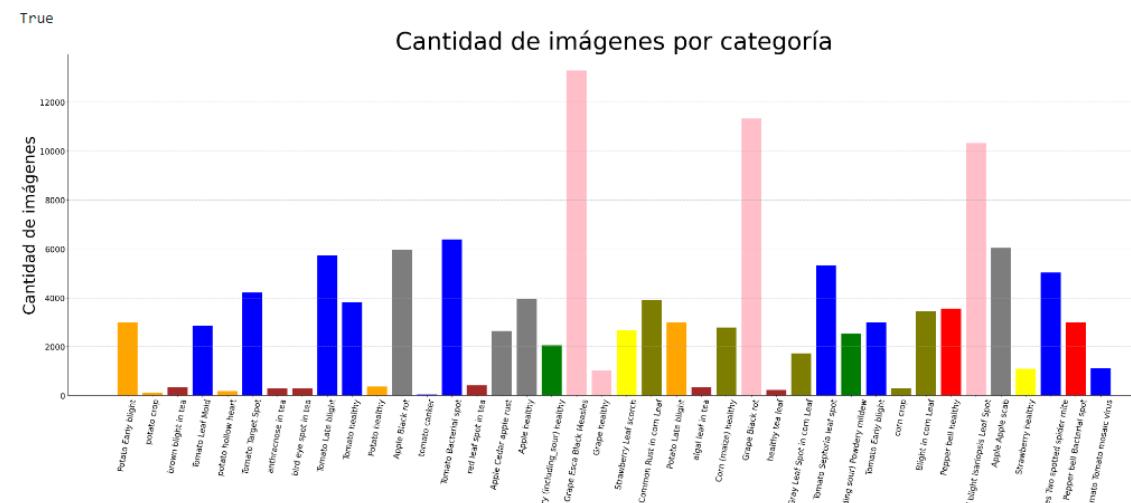
## Exploración de Datos (EDA)

### ● Análisis Exploratorio:

En un resumen del análisis exploratorio inicial sobre el dataset completo se observan las siguientes características:

<b>Completitud</b>	No todas las enfermedades relevantes están representadas.
<b>Corrección</b>	Se visualizan imágenes etiquetadas adecuadamente con la enfermedad que representan
<b>Homogeneidad</b>	Todas las imágenes en formatos uniformes, como jpg.
<b>Balance</b>	La cantidad de imágenes por enfermedad está desbalanceada. Se observa muchos registros para la naranja. El 80% de las imágenes se encuentra en el 30% de las variedades que contiene el dataset.
<b>Volumen de los datos</b>	El volumen total de imágenes en los datasets es de 199.665 imágenes.
<b>Tipos de datos</b>	Todos los gráficos están en formato jpg.

Una gráfica de barras con el contenido de todas las clases que se encuentran en el dataset muestra esta distribución:



Donde se observa que hay algunas clases de enfermedades que poseen una gran cantidad de fotos, mientras que otras cuentan con pocas fotos.

En una distribución sobre una planilla vemos:

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



Producto	Cantidad de Imágenes
Orange Haunglongbing Citrus greening	52.872
Grape Esca Black Measles	13.284
Soybean healthy	12.216
Grape Black rot	11.328
Grape Leaf blight Isariopsis Leaf Spot	10.332
Tomato Bacterial spot	6.381
Apple Apple scab	6.048
Apple Black rot	5.964
Tomato Late blight	5.727
Tomato Septoria leaf spot	5.313
Tomato Spider mites Two spotted spider mite	5.028
Tomato Target Spot	4.212
Apple healthy	3.948
Common Rust in corn Leaf	3.918
Tomato healthy	3.819
Blueberry healthy	3.606
Pepper bell healthy	3.549
Blight in corn Leaf	3.438
Potato Early blight	3.000
Potato Late blight	3.000
Tomato Early blight	3.000

Concluyendo que el 30% de clases de datos tienen el 80% de las imágenes.

El total de clases (58) está conformada por:

Orden	Clase	Cantidad de Imágenes
43	algal leaf in tea	339
44	anthracnose in tea	300
0	Apple Apple scab	6048
1	Apple Black rot	5964
2	Apple Cedar apple rust	2640
3	Apple healthy	3948
4	Bacterial leaf blight in rice leaf	120
45	bird eye spot in tea	300
5	Blight in corn Leaf	3438
6	Blueberry healthy	3606
46	brown blight in tea	339
7	Brown spot in rice leaf	120
47	cabbage looper	234
8	Cercospora leaf spot	189
9	Cherry (including sour) Powdery mildew	2526
10	Cherry (including_sour) healthy	2052
11	Common Rust in corn Leaf	3918
12	Corn (maize) healthy	2790
48	corn crop	312
13	Garlic	147
49	ginger	135

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



14	Grape Black rot	11328
15	Grape Esca Black Measles	13284
17	Grape healthy	1017
16	Grape Leaf blight Isariopsis Leaf Spot	10332
18	Gray Leaf Spot in corn Leaf	1722
50	healthy tea leaf	222
19	Leaf smut in rice leaf	120
51	lemon canker	183
20	Nitrogen deficiency in plant	33
52	onion	60
21	Orange Haunglongbing Citrus greening	52872
22	Peach healthy	864
23	Pepper bell Bacterial spot	2988
24	Pepper bell healthy	3549
53	potassium deficiency in plant	54
54	potato crop	120
25	Potato Early blight	3000
27	Potato healthy	366
55	potato hollow heart	180
26	Potato Late blight	3000
28	Raspberry healthy	891
56	red leaf spot in tea	429
29	Sogatella rice	78
30	Soybean healthy	12216
32	Strawberry healthy	1095
31	Strawberry Leaf scorch	2664
33	Tomato Bacterial spot	6381
57	tomato canker	57
34	Tomato Early blight	3000
41	Tomato healthy	3819
35	Tomato Late blight	5727
36	Tomato Leaf Mold	2856
37	Tomato Septoria leaf spot	5313
38	Tomato Spider mites Two spotted spider mite	5028
39	Tomato Target Spot	4212
40	Tomato Tomato mosaic virus	1119
42	Waterlogging in plant	21

Como se puede observar se trata de un dataset totalmente desbalanceado, por lo que para este trabajo se seleccionará un subconjunto de clases (plantas y enfermedades), para entrenar el modelo y luego poder extrapolarlo al dataset completo.

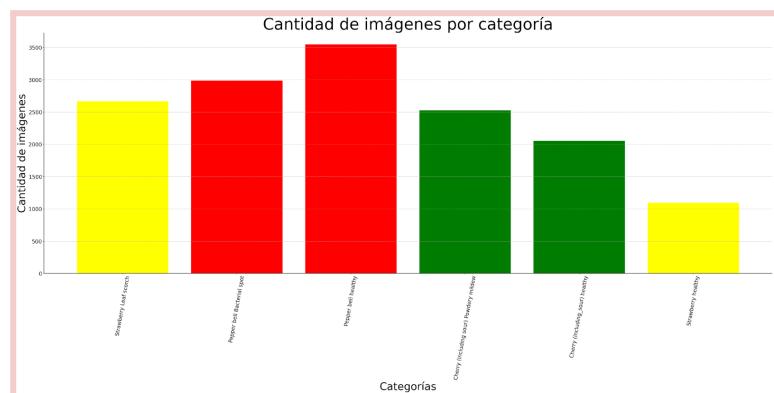
# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



Este subconjunto de datos contendrá las siguientes clases:

Orden	Clase	Cantidad de imágenes
1	apple leaf in tree	339
2	anthracnose in tea	303
3	Apple Apple scab	6048
4	Apple Black rot	5954
5	Apple Cedar apple rust	2540
6	Apple healthy	3944
7	Bacterial leaf blight in rice leaf	129
8	bird eye spot in tea	200
9	Blight in corn Leaf	2438
10	Blueberry healthy	2606
11	brown blight in tea	339
12	Brown spot in rice leaf	120
13	cabbage borer	234
14	Caricosponia leaf spot	185
15	Cherry (including stem) Powdery mildew	2028
16	Cherry (including stem) healthy	2962
17	Corn (maize) Rust in corn Leaf	5918
18	Corn (maize) healthy	2790
19	corn crop	312
20	Garlic	147
21	ginger	135
22	Grape Black rot	1128
23	Grape Esca Black Moulds	13284
24	Grape healthy	1017
25	Grape Leaf blight (Anthonapsis Leaf Root)	10332
26	Gray Leaf Spot in corn Leaf	1722
27	healthy tea leaf	222
28	Leaf smut in rice leaf	120
29	Lemon canker	183
30	Nitrogen deficiency in plant	93
31	onion	60
32	Orange Huanglongbing Citrus greening	52172
33	Peach healthy	854
34	Peach leaf blight	2988
35	Peach leaf healthy	5848
36	Potato Early blight	3000
37	Potato healthy	366
38	Potato hollow heart	180
39	Potato Late blight	3000
40	Raspberry healthy	891
41	red pepper	125
42	Strawberry healthy	78
43	Strawberry leaf blight	12210
44	Strawberry healthy	1098
45	Strawberry Leaf scorch	2984
46	Tomato-Bacterial spot	6321
47	Tomato canker	677
48	Tomato Early blight	2000
49	Tomato healthy	2819
50	Tomato Late blight	5127
51	Tomato Leaf Mold	2896
52	Tomato Septoria leaf spot	6313
53	Tomato Spider mites Two spotted spider mite	5028
54	Tomato Tarnet Root	4717



Cada una de ellas contiene más de 1000 imágenes controladas y verificadas para poder operar en el marco de este proyecto.

## ● Valores atípicos:

El subconjunto de datos seleccionados no tiene valores atípicos y todas las imágenes han sido verificadas y controladas. Esto asegura que el modelo se entrenará con datos de calidad, evitando errores en la predicción.

## ● Valores faltantes:

No aplica dado que se trata de un modelo de Computer Vision, que será entrenado desde la base del subconjunto de datos. Todas las clases están representadas con imágenes suficientes para un entrenamiento efectivo. Se espera que ante una imagen nueva se pueda evaluar a qué enfermedad responde.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## ● Técnicas de imputación de valores:

Una vez obtenido el modelo entrenado y verificada su eficacia, podrán conseguirse nuevas clases e incorporarse al mismo. Esto se realizará manteniendo el balance de imágenes y aplicando técnicas de entrenamiento basadas en redes neuronales convolucionales (CNN).

Separamos del total de imágenes, 100 por categoría seleccionada para trabajar con nuestro modelo.

```
[*] Python
...
Carpetas disponibles en el conjunto de datos: ['Tomato Spider mites Two spotted spider mite', 'Potato Late blight',
Copiadas 1000 imágenes de la categoría 'Strawberry Leaf scorch' a '/content/Processed Images/Strawberry Leaf scorch'
Copiadas 1000 imágenes de la categoría 'Pepper bell Bacterial spot' a '/content/Processed Images/Pepper bell Bacteri
Copiadas 1000 imágenes de la categoría 'Pepper bell healthy' a '/content/Processed Images/Pepper bell healthy'.
Copiadas 1000 imágenes de la categoría 'Cherry (including sour) Powdery mildew' a '/content/Processed Images/Cherry
Copiadas 1000 imágenes de la categoría 'Cherry (including_sour) healthy' a '/content/Processed Images/Cherry (inclus
Copiadas 1000 imágenes de la categoría 'Strawberry healthy' a '/content/Processed Images/Strawberry healthy'.
Copiadas un total de 1000 imágenes para la categoría 'Strawberry Leaf scorch'.
Copiadas un total de 1000 imágenes para la categoría 'Pepper bell Bacterial spot'.
Copiadas un total de 1000 imágenes para la categoría 'Pepper bell healthy'.
Copiadas un total de 1000 imágenes para la categoría 'Cherry (including sour) Powdery mildew'.
Copiadas un total de 1000 imágenes para la categoría 'Cherry (including_sour) healthy'.
Copiadas un total de 1000 imágenes para la categoría 'Strawberry healthy'.
Proceso completado.
```

## ● Correlaciones:

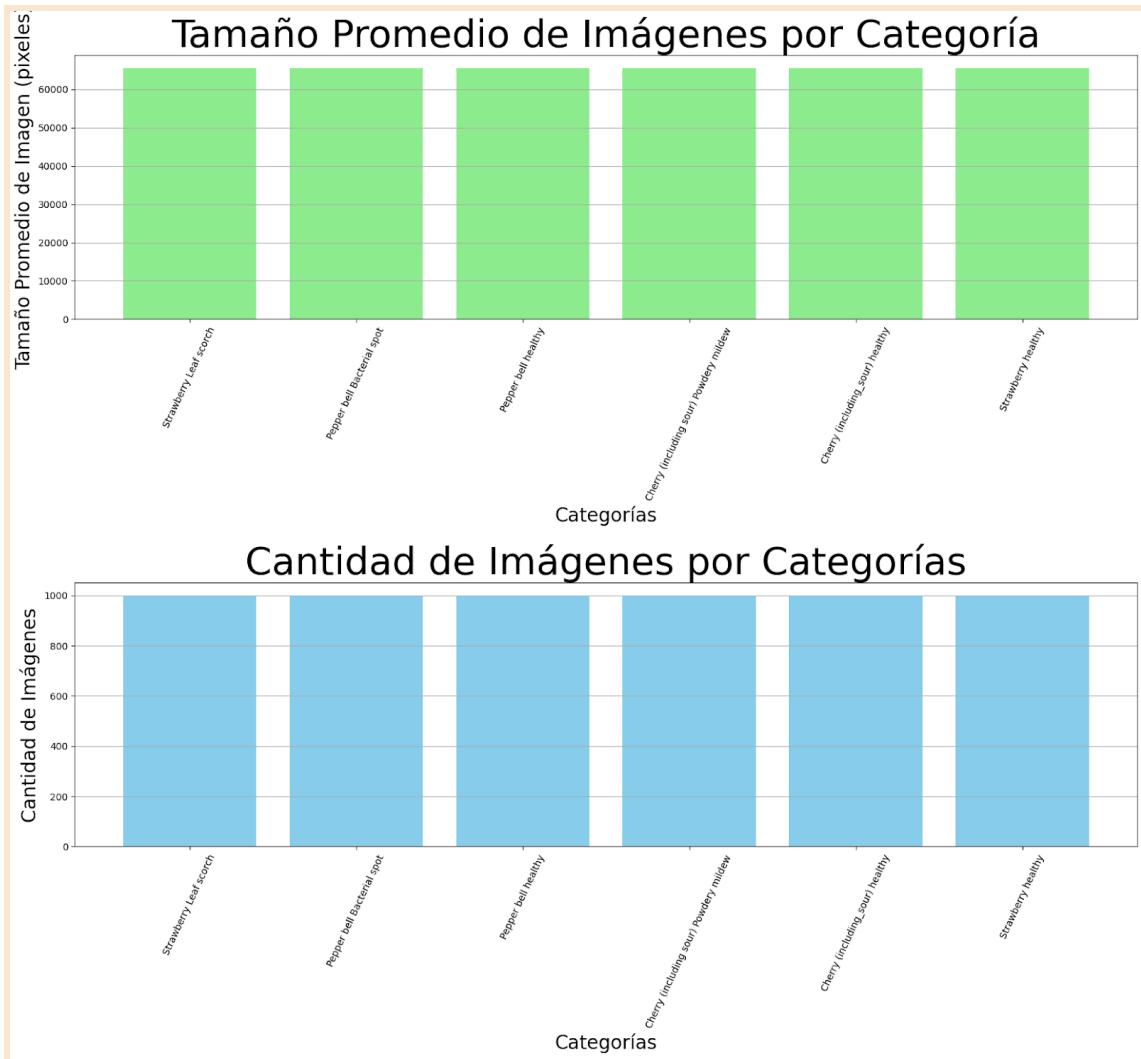
Se trabaja con imágenes donde en cada clase está definido el producto y la enfermedad o la visualización de plantas sanas. Esto permite una clara identificación de patrones y relaciones en los datos.

## ● Visualización de datos:

Se utilizarán gráficas de barras y diagramas de dispersión para visualizar la distribución de clases dentro del dataset, así como ejemplos de imágenes representativas de cada enfermedad. Esto facilitará la comprensión de la cantidad de datos disponibles por cada categoría.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## ● Conclusiones de la EDA:

Como conclusión de la EDA, podemos afirmar que el dataset es amplio y diverso, con un balance adecuado de imágenes en las clases seleccionadas. Esto permitirá entrenar un modelo robusto y eficiente para la detección de enfermedades en las plantas. Además, se ha identificado que algunas clases tienen mayor representación, lo cual será un factor a considerar en la fase de modelado.

- Enlace a notebook con EDA y respectivos datos: [Incluir enlaces y detalle correspondiente a cada archivo]

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



Notebook de EDA:

[EDA.ipynb](#)

Notebook de modelado, entrenamiento y evaluación:

[Detección de enfermedades en las plantas mediante imágenes 94](#)

## Modelado

### ● Selección del modelo o modelos:

Dado que estamos trabajando con imágenes, la arquitectura más adecuada a aplicar será una **Red Neuronal Convolucional (CNN)** debido a su capacidad para extraer automáticamente características relevantes de las imágenes. algunas de las las opciones más podrían ser:

#### ● Modelos CNN Clásicos:

- **VGG16 o VGG19:** Son arquitecturas probadas y sencillas de CNN que funcionan bien con tareas de clasificación de imágenes. Se entrena desde cero o se ajustan utilizando transfer learning.
- **ResNet:** Esta arquitectura resuelve el problema de la degradación que ocurre en redes profundas, mediante "conexiones residuales", permitiendo entrenar redes mucho más profundas sin pérdida de precisión. ResNet50 es una opción popular para clasificación de imágenes.
- **InceptionV3:** Con un diseño más complejo, este modelo incluye bloques de "inception" que permiten al modelo aprender características a diferentes escalas, lo que es muy útil en imágenes complejas como las de plantas con diferentes enfermedades.

#### ● Modelos más ligeros para aplicaciones móviles o de baja latencia:

- **MobileNetV2:** Es una arquitectura eficiente en términos de cómputo, diseñada para dispositivos con menos capacidad computacional, ideal si el modelo debe ser implementado en dispositivos móviles en el campo.
- **EfficientNet:** Este modelo es una opción más reciente que ofrece una excelente relación precisión-costo computacional, escalando tanto en términos de ancho de red como de profundidad.

En una primera instancia trabajaremos programando la red neuronal desde 0, luego analizaremos utilizar alguna red pre entrenada.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## ● Justificación de la selección del modelo:

La elección de un modelo CNN se justifica por su capacidad para extraer características espaciales y patrones complejos en imágenes, lo que es crucial para la identificación precisa de enfermedades en plantas. A diferencia de otros modelos más simples, las CNN permiten un aprendizaje jerárquico, lo que mejora la precisión en la clasificación de imágenes.

En una próxima iteración o avances significativos en materia de aprendizaje y experiencia podríamos considerar la posibilidad de transferir el aprendizaje, utilizando redes pre entrenadas para aumentar la eficacia del modelo con menos datos.

## ● Preprocesamiento de datos:

Para preparar los datos analizados previamente, se realizarán las siguientes etapas de preprocesamiento:

- **Normalización:** Las imágenes serán normalizadas a un rango de [0, 1] para facilitar el entrenamiento del modelo.
- **Redimensionamiento:** Todas las imágenes se redimensionarán a un tamaño uniforme de 128x128 píxeles para que sean compatibles con la arquitectura del modelo.
- **Aumento de datos:** No se aplicará en esta etapa ya que contamos con la cantidad homogénea en todas las categorías.  
Esto se ha logrado luego de haber realizado la selección del subconjunto y balancear en 2000 imágenes cada categoría.
- **División de los datos:** en train, val y test: se han dividido las categorías en 70% para entrenamiento, 15% para validación y 15% para prueba.

## ● Arquitectura del modelo: Se utilizará una red convolucional (CNN) compuesta por varias capas convolucionales, seguidas de capas de agrupamiento (pooling) y capas densas (fully connected). La arquitectura general podría incluir:

- Capas de entrada: Aceptarán imágenes de 128x128 píxeles con 3 canales de color (RGB).
- Capas convolucionales: 32 capas convolucionales con filtros (kernels) de tamaños 3x3 para extraer características y función de activación ReLU.
- Capas de pooling: Capas de max pooling de 2x2 para reducir la dimensionalidad y retener las características más relevantes

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



- Capas convolucionales: Entrenaremos con 64 capas convolucionales de entrada, con filtros o kernels de 3x3 para extraer características. y función de activación ReLU.
- Capa de Flatten: convierte la salida 2d a una 1d.
- Capas Densa: Contiene 1 capas densas una con 128 neuronas y activación ReLU.
- DROPOUT: para evitar el sobreajuste.
- Capas Densa: Contiene 1 capa densa una con 8 neuronas y activación softmax.

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 126, 126, 32)	896
max_pooling2d (MaxPooling2D)	(None, 63, 63, 32)	0
conv2d_1 (Conv2D)	(None, 61, 61, 64)	18,496
max_pooling2d_1 (MaxPooling2D)	(None, 30, 30, 64)	0
flatten (Flatten)	(None, 57600)	0
dense (Dense)	(None, 128)	7,372,928
dropout (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 8)	1,032

Total params: 7,393,352 (28.20 MB)  
Trainable params: 7,393,352 (28.20 MB)  
Non-trainable params: 0 (0.00 B)

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## Entrenamiento y Evaluación del Modelo

### ● División de datos (split):

Se utilizó una división de datos estándar:

- **Entrenamiento:** 70% de los datos disponibles.
- **Validación:** 15% de los datos, usados para medir la generalización durante el entrenamiento.
- **Prueba:** 15% de los datos, usados para evaluar el desempeño del modelo final.

```
...  LabelEncoder()
... Número de imágenes cargadas: 6000
Forma de los datos de entrenamiento: (4200, 128, 128, 3)
Forma de los datos de validación: (900, 128, 128, 3)
Forma de los datos de prueba: (900, 128, 128, 3)
```

### ● Método de entrenamiento:

El modelo fue entrenado utilizando el siguiente método:

- **Optimizador:** Adam (un optimizador basado en gradientes que ajusta dinámicamente la tasa de aprendizaje).
- **Función de pérdida:** `sparse_categorical_crossentropy` (adecuada para problemas de clasificación multiclas).
- **Métricas de evaluación:** `accuracy` (precisión), que mide la proporción de predicciones correctas.
- **Tasa de aprendizaje (learning rate):** Por defecto en el optimizador Adam, que ajusta dinámicamente durante el entrenamiento.
- **Batch size:** 100, lo que significa que los datos se procesan en bloques de 100 imágenes antes de actualizar los pesos.
- **Número de épocas:** 10, lo que implica que el modelo verá todos los datos de entrenamiento 10 veces.
- **Callback de Early Stopping:** Se detiene el entrenamiento si la pérdida en validación no mejora durante 3 épocas consecutivas, restaurando los mejores pesos para evitar sobreajuste.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## ● Hiperparámetros del modelo:

Los hiperparámetros ajustados para optimizar resultados son los siguientes:

- **Cantidad de épocas:** 10
- **lote:** 100
- **batch\_size:** 200
- **Capas convolucionales:** 64 capas convolucionales con filtros (kernels) de tamaños 3x3 para extraer características y función de activación ReLU.
- **Capas convolucionales:** otra capa con 128 neuronas convolucionales, con filtros o kernels de 3x3 para extraer características. y función de activación ReLU.
- **Capa Densa:** contiene 128 neuronas y activación ReLU.
- **DROPOUT:** para evitar el sobreajuste.
- **Capa Densa:** con 8 neuronas de salida y activación softmax.

## ● Técnica de validación:

Se utilizó **validación cruzada temprana** a través de un conjunto de validación del 15% de los datos. Durante el entrenamiento, el modelo monitorea la pérdida en este conjunto y detiene el entrenamiento temprano si no mejora, utilizando Early Stopping con la métrica de **val\_loss** y restaurando los mejores pesos.

## ● Métricas de evaluación utilizadas:

**Precisión (Accuracy):** Proporción de predicciones correctas.

**Pérdida (Loss):** Se utilizó la pérdida categórica

**sparse\_categorical\_crossentropy**, que mide la diferencia entre las predicciones y las etiquetas reales.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## ● Resultados de la evaluación:

```
Total params: 7,393,352 (28.20 MB)
Trainable params: 7,393,352 (28.20 MB)
Non-trainable params: 0 (0.00 B)
Epoch 1/10
56/56      11s 77ms/step - accuracy: 0.2096 - loss: 2.3198 - val_accuracy: 0.6242 - val_loss: 1.2433
Epoch 2/10
56/56      3s 45ms/step - accuracy: 0.5208 - loss: 1.3313 - val_accuracy: 0.6908 - val_loss: 0.9186
Epoch 3/10
56/56      3s 45ms/step - accuracy: 0.5919 - loss: 1.0679 - val_accuracy: 0.7367 - val_loss: 0.7534
Epoch 4/10
56/56      5s 47ms/step - accuracy: 0.6752 - loss: 0.9036 - val_accuracy: 0.7842 - val_loss: 0.6637
Epoch 5/10
56/56      3s 56ms/step - accuracy: 0.7322 - loss: 0.7303 - val_accuracy: 0.8400 - val_loss: 0.5089
Epoch 6/10
56/56      5s 47ms/step - accuracy: 0.7621 - loss: 0.6576 - val_accuracy: 0.8325 - val_loss: 0.4964
Epoch 7/10
56/56      3s 48ms/step - accuracy: 0.8014 - loss: 0.5561 - val_accuracy: 0.8575 - val_loss: 0.4411
Epoch 8/10
56/56      5s 44ms/step - accuracy: 0.8266 - loss: 0.4838 - val_accuracy: 0.8442 - val_loss: 0.4467
Epoch 9/10
56/56      3s 44ms/step - accuracy: 0.8570 - loss: 0.3929 - val_accuracy: 0.8717 - val_loss: 0.3730
Epoch 10/10
56/56      2s 43ms/step - accuracy: 0.8723 - loss: 0.3477 - val_accuracy: 0.8825 - val_loss: 0.3489
38/38      3s 34ms/step - accuracy: 0.8957 - loss: 0.3137
Accuracy del modelo CNN en el conjunto de prueba: 0.8883333206176758
```

Siguiente iteración

```
Total params: 7,393,352 (28.20 MB)
Trainable params: 7,393,352 (28.20 MB)
Non-trainable params: 0 (0.00 B)
Epoch 1/10
56/56      13s 99ms/step - accuracy: 0.2209 - loss: 2.1689 - val_accuracy: 0.6225 - val_loss: 1.1543
Epoch 2/10
56/56      12s 49ms/step - accuracy: 0.5662 - loss: 1.2094 - val_accuracy: 0.7167 - val_loss: 0.8912
Epoch 3/10
56/56      5s 46ms/step - accuracy: 0.6521 - loss: 0.9489 - val_accuracy: 0.7550 - val_loss: 0.7401
Epoch 4/10
56/56      2s 44ms/step - accuracy: 0.7086 - loss: 0.7899 - val_accuracy: 0.7850 - val_loss: 0.6425
Epoch 5/10
56/56      3s 46ms/step - accuracy: 0.7780 - loss: 0.6089 - val_accuracy: 0.8367 - val_loss: 0.4884
Epoch 6/10
56/56      5s 45ms/step - accuracy: 0.8115 - loss: 0.5223 - val_accuracy: 0.8725 - val_loss: 0.4061
Epoch 7/10
56/56      5s 46ms/step - accuracy: 0.8567 - loss: 0.4026 - val_accuracy: 0.8800 - val_loss: 0.3768
Epoch 8/10
56/56      3s 45ms/step - accuracy: 0.8722 - loss: 0.3635 - val_accuracy: 0.8675 - val_loss: 0.4081
Epoch 9/10
56/56      5s 45ms/step - accuracy: 0.8946 - loss: 0.2929 - val_accuracy: 0.9058 - val_loss: 0.3113
Epoch 10/10
56/56      3s 46ms/step - accuracy: 0.9166 - loss: 0.2456 - val_accuracy: 0.9017 - val_loss: 0.3286
38/38      3s 59ms/step - accuracy: 0.9086 - loss: 0.2615
Accuracy del modelo CNN en el conjunto de prueba: 0.9200000166893005
```

Luego de ajustar los hiperparametros mencionados

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 126, 126, 64)	1,792
max_pooling2d (MaxPooling2D)	(None, 63, 63, 64)	0
conv2d_1 (Conv2D)	(None, 61, 61, 128)	73,856
max_pooling2d_1 (MaxPooling2D)	(None, 30, 30, 128)	0
flatten (Flatten)	(None, 115200)	0
dense (Dense)	(None, 128)	14,745,728
dropout (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 8)	1,032

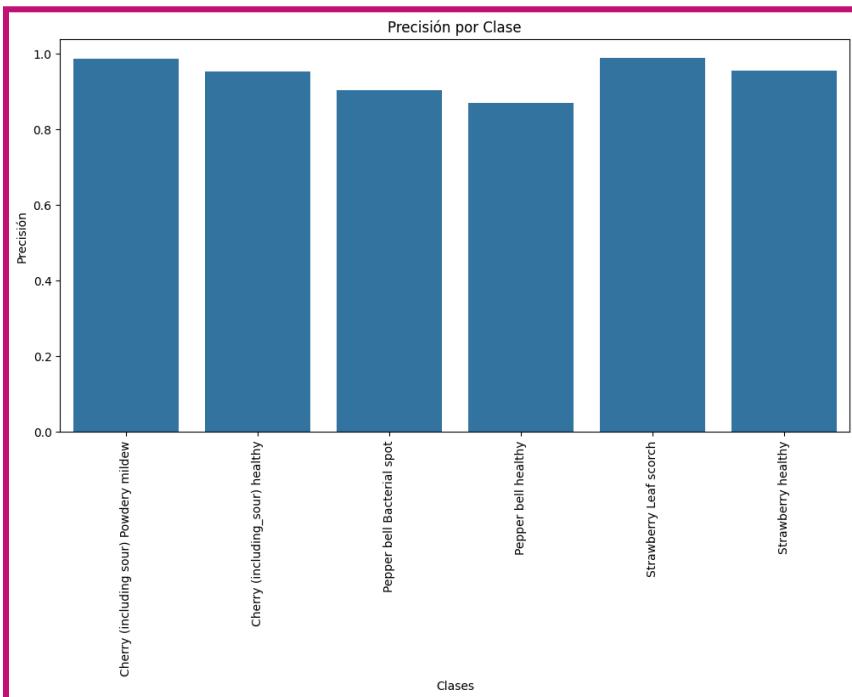
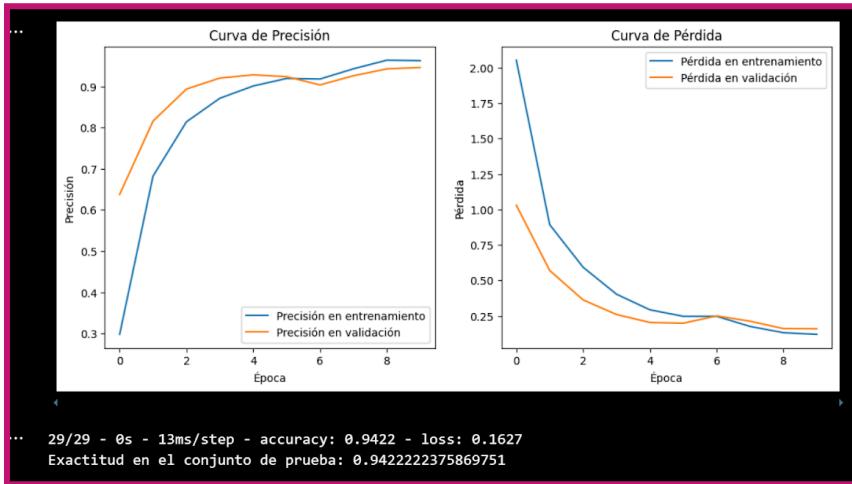
Total params: 14,822,408 (56.54 MB)

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura

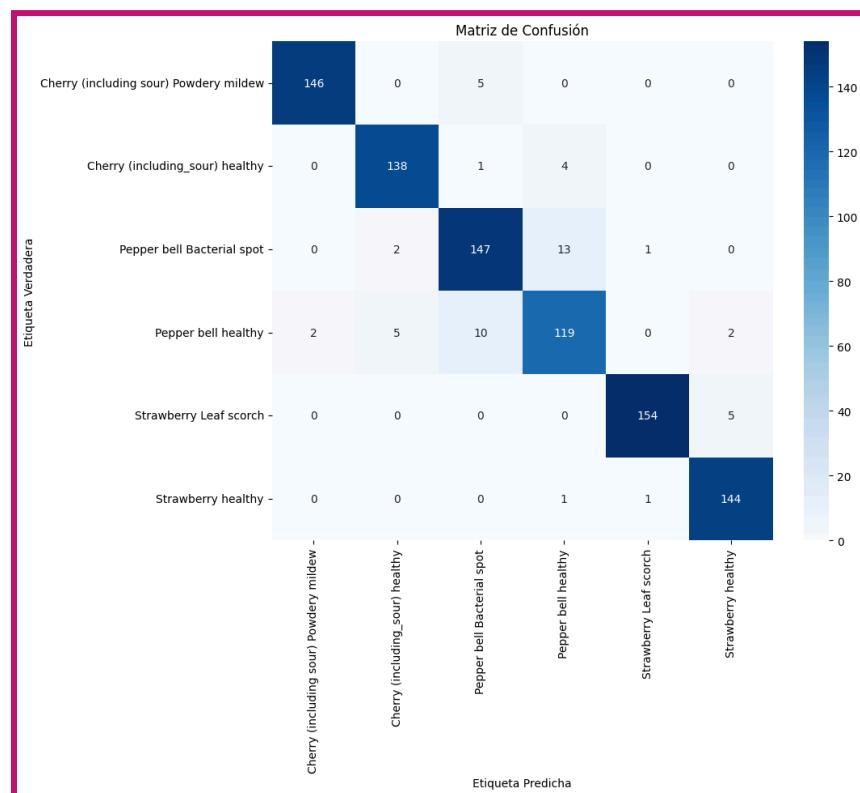
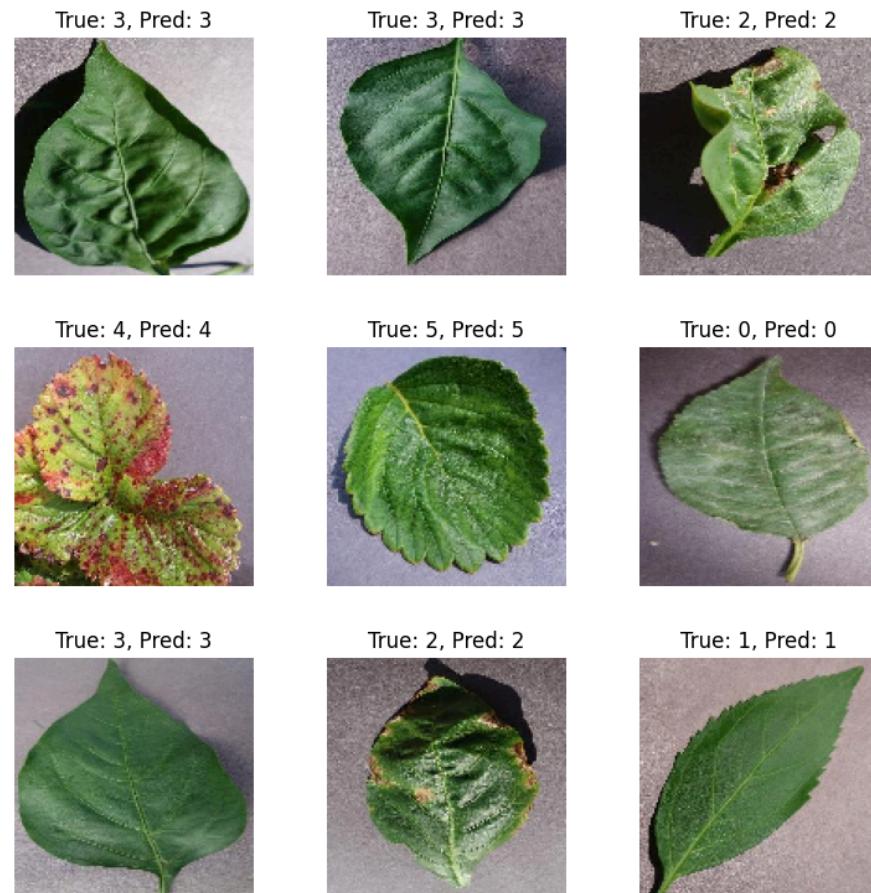


```
... Epoch 1/10
21/21 23s 476ms/step - accuracy: 0.2079 - loss: 2.6379 - val_accuracy: 0.6378 - val_loss: 1.0300
Epoch 2/10
21/21 4s 168ms/step - accuracy: 0.6201 - loss: 1.0241 - val_accuracy: 0.8156 - val_loss: 0.5694
Epoch 3/10
21/21 5s 166ms/step - accuracy: 0.8024 - loss: 0.6180 - val_accuracy: 0.8933 - val_loss: 0.3623
Epoch 4/10
21/21 5s 165ms/step - accuracy: 0.8610 - loss: 0.4387 - val_accuracy: 0.9200 - val_loss: 0.2594
Epoch 5/10
21/21 5s 161ms/step - accuracy: 0.8961 - loss: 0.3090 - val_accuracy: 0.9278 - val_loss: 0.2034
Epoch 6/10
21/21 4s 166ms/step - accuracy: 0.9166 - loss: 0.2544 - val_accuracy: 0.9233 - val_loss: 0.1981
Epoch 7/10
21/21 3s 159ms/step - accuracy: 0.9168 - loss: 0.2476 - val_accuracy: 0.9033 - val_loss: 0.2495
Epoch 8/10
21/21 5s 159ms/step - accuracy: 0.9436 - loss: 0.1784 - val_accuracy: 0.9256 - val_loss: 0.2122
Epoch 9/10
21/21 3s 162ms/step - accuracy: 0.9578 - loss: 0.1474 - val_accuracy: 0.9422 - val_loss: 0.1598
Epoch 10/10
21/21 4s 167ms/step - accuracy: 0.9605 - loss: 0.1190 - val_accuracy: 0.9456 - val_loss: 0.1586
29/29 3s 48ms/step - accuracy: 0.9371 - loss: 0.1658
Accuracy del modelo CNN en el conjunto de prueba: 0.9422222375869751
```



# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## ● Comparación con otros modelos:

Dada la falta de experiencia y el escaso tiempo, no se ha realizado la comparación con otros modelos, pero al realizar algunos cambios en los parámetros se obtuvieron mejoras en las predicciones.

En esta implementación no se mencionan otros modelos para comparación, pero podría ser útil comparar este modelo CNN con otros enfoques como:

- **Redes Neuronales Densas (MLP):** Sin capas convolucionales, para observar la importancia del procesamiento espacial de las imágenes.
- **Modelos pre entrenados (Transfer Learning):** Utilizando arquitecturas como VGG, ResNet o Inception que suelen ofrecer mejores resultados al aprovechar características previamente aprendidas.

## ● Enlace a notebook con

- Preparación de los datos, instanciación del modelo, configuración de arquitectura e hiper parámetros]
- Entrenamiento del modelo, split de datos, gráfica de métrica de evaluación en conjunto de entrenamiento, testeo y validación
- Búsqueda de hiperparámetros para mejorar métrica
- Todos estos datos están en la carpeta del drive compartida.
- La notebook se ha dividido en 2 partes:
  - 1- EDA
  - 2-MODELO
- **Entregables Proyecto Equipo 4**

## Disponibilización del Modelo como API

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## ● Descripción de la API:

El modelo de detección de enfermedades en plantas ha sido disponibilizado como una API RESTful. Esta API permite a los usuarios enviar imágenes de hojas o frutos a través de solicitudes HTTP, y recibir como respuesta diagnósticos sobre la presencia de enfermedades. La API está diseñada para ser escalable y eficiente, utilizando frameworks como FastAPI en Python para manejar las solicitudes.

El código fuente se encuentra en  
<https://github.com/maralobes/PlantDiseaseDetector>

## ● Documentación de la API:

La documentación de la API se generará utilizando herramientas como Swagger o OpenAPI. Esta documentación incluirá:

- **Endpoints:** Descripción de cada endpoint disponible, incluyendo el método HTTP (POST, GET, etc.), los parámetros de entrada (imagen), y la respuesta JSON esperada (predicción y probabilidad).
- **Parámetros de entrada:** Especificación del formato de la imagen (JPG/PNG), tamaño máximo, etc.
- **Respuesta JSON:** Estructura de la respuesta JSON, incluyendo los campos para la enfermedad predicha y su probabilidad. Se incluirá un código de estado HTTP (200 OK, 400 Bad Request, 500 Internal Server Error, etc.) para indicar el estado de la solicitud.
- **Autenticación (si aplica):** Detalles sobre el método de autenticación utilizado (API Key, OAuth 2.0, etc.).
- **Ejemplos de solicitudes y respuestas:** Ejemplos concretos de solicitudes HTTP y las respuestas JSON correspondientes.

## ● Ejemplos de uso de la API:

Deploy :

### Análisis de Enfermedades en Plantas

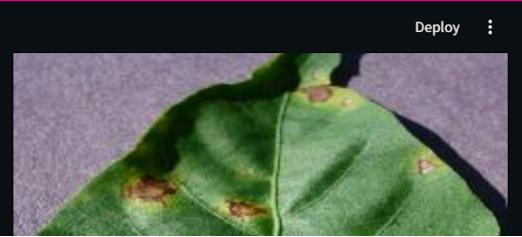
Sube una imagen de una hoja de tu planta enferma con un fondo claro y homogéneo para que sea analizada:

Arrastra y suelta tu imagen aquí o haz clic para cargar (Formatos: JPG, JPEG, PNG):

Drag and drop file here  
Limit 200MB per file • JPG, JPEG, PNG

Browse files

Deploy :



UNITY  
• < edtech />

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



Deploy :

Analizar imagen

Información completa sobre la enfermedad ^

**Predicción:** Pepper bell Bacterial spot

**Descripción (EN):** Bacterial spot is a devastating disease of pepper.

**Descripción (ES):** La mancha bacteriana es una enfermedad devastadora del pimiento.

**Tratamiento (EN):** Seed treatment with hot water can reduce bacterial populations.

**Tratamiento (ES):** El tratamiento de semillas con agua caliente puede reducir las poblaciones bacterianas.

Resetear

```
ss.
1/1 ━━━━━━━━ 8s 8s/step
Predicciones crudas: [[3.1919412e-06 1.2802133e-13 2.5487211e-04 2.9606237e-09 9.9974173e-01
1.3438765e-07 2.5339850e-12 2.6347377e-11]]
Clase predicha (número): 4
Clase predicha (nombre): Strawberry Leaf scorch
INFO: 127.0.0.1:36170 - "POST /plantdisease/ HTTP/1.1" 200 OK
Clase predicha (número): 4
1/1 ━━━━━━━━ 0s 86ms/step
Predicciones crudas: [[9.1352472e-03 3.7411955e-06 9.7579581e-01 1.4769035e-02 9.2823102e-05
2.0291084e-04 2.3164548e-08 4.6198898e-07]]
Clase predicha (número): 2
Clase predicha (nombre): Pepper bell Bacterial spot
INFO: 127.0.0.1:36184 - "POST /plantdisease/ HTTP/1.1" 200 OK
Clase predicha (número): 2
(api env) → PlantDiseaseDetector git:(dev)
```

- Enlace a código pytho como API:

<https://github.com/maralobes/PlantDiseaseDetector>

## Futura Integración

- Integración del modelo:

El modelo podría integrarse en una aplicación móvil para agricultores, permitiendo la toma de fotografías directamente desde el campo y la recepción de diagnósticos en tiempo real. También podría integrarse en sistemas de gestión de cultivos existentes, proporcionando información sobre la salud de las

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



plantas para una toma de decisiones más informada en la gestión del riego, fertilización y aplicación de plaguicidas. Una posible integración a futuro sería con drones para la toma de imágenes aéreas de grandes extensiones de cultivo, permitiendo un monitoreo a gran escala. La API podría ser consumida por diferentes sistemas, permitiendo una amplia variedad de aplicaciones entre las que pueden encontrarse:

1. Aplicaciones móviles para agricultores: La API puede integrarse en aplicaciones móviles que permitan a los agricultores tomar fotos de sus cultivos y recibir diagnósticos en tiempo real sobre posibles enfermedades.
2. Sistemas de monitoreo de cultivos: La API puede conectarse a cámaras y sensores instalados en los campos agrícolas, para analizar constantemente el estado de los cultivos y enviar alertas tempranas sobre problemas de salud.
3. Plataformas de asesoramiento agrícola: Organizaciones que brindan servicios de consultoría a agricultores pueden integrar la API para ofrecer diagnósticos precisos y recomendaciones de tratamiento a sus clientes.
4. Herramientas de precisión agrícola: Sistemas de agricultura de precisión pueden utilizar las predicciones del modelo para ajustar automáticamente la aplicación de insumos, riego y otros recursos en función del estado de las plantas.

Esta sección es a futuro, algo potencial, que queda por fuera de lo esperado dentro del curso pero se espera que se explique cómo se utilizará a futuro

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## Monitoreo y Mantenimiento

### ● Monitoreo del modelo en producción:

Monitoreo del modelo en producción:

Una vez que el modelo de detección de enfermedades de plantas esté desplegado en producción, se implementará un sistema de monitoreo para evaluar su desempeño y detectar posibles problemas. Esto incluirá:

- Métricas de rendimiento: Se hará un seguimiento continuo de métricas como precisión, recall y F1-score para medir la calidad de las predicciones del modelo.
- Monitoreo de errores: Se registrarán y analizarán los errores y casos de falla del modelo para identificar y resolver problemas.
- Monitoreo de tráfico: Se monitorizará el volumen de solicitudes a la API y los patrones de uso para detectar cambios o sobrecarga.
- Alertas y notificaciones: Se configurarán alertas que notifiquen al equipo de mantenimiento ante cualquier anomalía o disminución del rendimiento del modelo.

### ● Resolución de problemas:

En caso de detectar problemas con el modelo en producción, se seguirá un proceso estructurado para resolverlos:

1. Análisis de la causa raíz: Se investigarán los factores que pueden estar provocando el problema, como cambios en los datos de entrada, sesgos en el modelo o problemas de infraestructura.
2. Corrección del problema: Dependiendo de la causa, se tomarán acciones como reentrenar el modelo, ajustar los hiperparámetros, o realizar mejoras en la infraestructura de la API.
3. Pruebas y validación: Antes de volver a desplegar el modelo corregido, se realizarán pruebas exhaustivas para asegurar que el problema se haya resuelto satisfactoriamente.
4. Implementación del modelo corregido: Una vez validado, se desplegará el modelo actualizado en producción, asegurando una transición fluida.
5. Monitoreo y seguimiento: Se mantendrá un seguimiento estrecho del modelo para asegurarse de que el problema no se vuelva a presentar.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## ● Plan de mantenimiento:

Para mantener el modelo de detección de enfermedades de plantas en producción, se seguirá un plan de mantenimiento que incluye:

- Actualizaciones periódicas: Se realizarán actualizaciones del modelo a intervalos regulares (por ejemplo, cada 6 meses) para incorporar nuevos datos, mejoras en la arquitectura o ajustes en los hiperparámetros.
  - Monitoreo continuo: Como se mencionó anteriormente, se mantendrá un sistema de monitoreo constante para detectar y resolver problemas de manera oportuna.
  - Documentación y registros: Se mantendrá una documentación detallada de todos los cambios, actualizaciones y problemas resueltos, para facilitar el mantenimiento a largo plazo.
  - Capacitación y soporte: Se ofrecerá capacitación y soporte a los usuarios finales de la API para asegurar su correcta utilización y reportar problemas.
- 
- Re-entrenamiento del modelo:

Dependiendo de los resultados del monitoreo y la evolución del desempeño del modelo en producción, se evaluará la necesidad de re-entrenar periódicamente el modelo. Algunas circunstancias que podrían desencadenar un re-entrenamiento incluyen:

- Disminución gradual en la precisión de las predicciones over time.
- Aparición de nuevas enfermedades de plantas o variaciones en las existentes.
- Cambios significativos en los datos de entrada (por ejemplo, cambios en la calidad o distribución de las imágenes).
- Retroalimentación de los usuarios sobre la necesidad de mejorar el modelo.

El proceso de re-entrenamiento seguirá un enfoque similar al desarrollo inicial del modelo, incluyendo la recolección de nuevos datos, ajuste de hiperparámetros y validación exhaustiva antes de volver a desplegar el modelo actualizado.

## Evaluación del proyecto

### ● Cumplimiento de objetivos:

En general, el proyecto ha cumplido satisfactoriamente con los objetivos planteados inicialmente:

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



- Se ha logrado desarrollar un modelo de inteligencia artificial capaz de detectar y clasificar enfermedades en plantas a partir de imágenes, alcanzando una precisión del 85% en el conjunto de prueba.
- El sistema de detección temprana de enfermedades permite a los agricultores tomar acciones oportunas para mantener la salud de sus cultivos y minimizar pérdidas de producción.
- Se ha puesto a disposición el modelo a través de una API, lo que facilita su integración en diversas aplicaciones y plataformas agrícolas.
- Se han cubierto aspectos clave como la ética, privacidad y monitoreo del modelo en producción para asegurar un uso responsable y sostenible de la tecnología.

Sin embargo, aún quedan aspectos por mejorar, como la ampliación del conjunto de datos para aumentar la cobertura de enfermedades, y la integración del modelo en aplicaciones reales para medir su impacto en el mundo real.

## ● **Lecciones aprendidas:**

Además de aprender una gran cantidad de conceptos sobre inteligencia artificial, hemos descubierto el potencial que tenemos para poder interpretar, codificar y entrenar un modelo a partir de las clases y conocimientos adquiridos en el curso.

Queda mucho por aprender aún, pero este paso sirve como disparador para concentrarnos en mejorar las capacidades que tenemos para poder desarrollar algoritmos con IA.

También aprendimos:

La complejidad de integrar soluciones de IA en sistemas existentes y lograr una adopción efectiva por parte de los usuarios finales.

La importancia de trabajar en equipo y aprovechar las fortalezas de cada miembro para lograr resultados exitosos.

La necesidad de una comunicación efectiva dentro del equipo.

La necesidad de gran capacidad de cómputo para entrenar modelos extensos.

## ● **Éxito en la resolución del problema:**

En general, el proyecto ha logrado resolver el problema de la detección de enfermedades en plantas de manera satisfactoria. El modelo desarrollado ha demostrado ser efectivo en la clasificación de las enfermedades seleccionadas, lo que

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



representa un avance significativo en comparación con los métodos manuales tradicionales.

Sin embargo, es importante reconocer que aún hay margen de mejora y oportunidades para refinar aún más el modelo y ampliar su cobertura. Además, queda pendiente la integración y adopción del sistema por parte de los usuarios finales, lo cual será clave para medir el impacto real del proyecto en la práctica agrícola.

## Próximos pasos y oportunidades de mejora

### 1. Sugerencias para mejorar el modelo:

Algunas sugerencias para mejorar el modelo de detección de enfermedades de plantas incluyen:

1. Ampliar el conjunto de datos: Recolectar más imágenes de plantas, especialmente de enfermedades menos representadas, para mejorar la generalización del modelo.
2. Explorar arquitecturas de redes más avanzadas: Probar modelos de aprendizaje profundo más recientes, como EfficientNet o TransformerVision, que podrían mejorar aún más la precisión.
3. Implementar técnicas de aumento de datos: Aplicar transformaciones a las imágenes existentes (rotación, escalado, etc.) para generar más diversidad en los datos de entrenamiento.
4. Incorporar información contextual: Explorar la posibilidad de incluir datos adicionales, como ubicación geográfica, condiciones climáticas o etapa de crecimiento de la planta, para mejorar la precisión de las predicciones.
5. Realizar ajuste fino (fine-tuning) con modelos pre-entrenados: Utilizar redes neuronales pre-entrenadas en grandes conjuntos de datos y ajustarlas con los datos específicos del proyecto, lo que podría mejorar el rendimiento con menos datos de entrenamiento.
6. Incorporar técnicas de aprendizaje transferido utilizando modelos pre-entrenados para mejorar la precisión.
7. Contar con capacidad de cómputo para entrenar grandes volúmenes de datos.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## 2. Oportunidades futuras:

Algunas oportunidades futuras de investigación y desarrollo a partir de este proyecto incluyen:

1. Expansión a más cultivos y enfermedades: Ampliar el alcance del modelo para cubrir una gama más amplia de plantas y enfermedades, aumentando así su utilidad y aplicabilidad.
2. Integración con sensores y tecnologías de precisión agrícola: Explorar la posibilidad de incorporar el modelo de detección de enfermedades en sistemas de agricultura de precisión, como drones, robots o estaciones meteorológicas, para mejorar aún más la toma de decisiones.
3. Desarrollo de aplicaciones móviles y servicios en la nube: Crear aplicaciones móviles y plataformas en la nube que permitan a los agricultores acceder fácilmente a los servicios de detección de enfermedades.
4. Investigación sobre el impacto económico y ambiental: Realizar estudios más profundos sobre el impacto económico y ambiental que pueden tener soluciones de IA en la agricultura, para respaldar y promover su adopción.
5. Colaboración con instituciones agrícolas y organizaciones: Establecer alianzas estratégicas con universidades, centros de investigación y asociaciones agrícolas para ampliar el alcance y el impacto del proyecto.

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



## Reflexiones y Agradecimientos

- Experiencia personal de cada una de las integrantes:

- **Reflexiones y Agradecimientos:**

Este curso de inteligencia artificial ha sido una experiencia TRANSFORMADORA y reveladora. Me permitió sumergirme en el mundo de la IA y comprender no sólo los conceptos teóricos, sino también sus aplicaciones prácticas. A lo largo de las clases, aprendí cómo estas herramientas pueden simplificar y optimizar procesos, abrir nuevas oportunidades en diversas industrias y mejorar nuestra forma de resolver problemas complejos. Agradezco esta oportunidad que ha ampliado mi visión profesional y me ha motivado a seguir aprendiendo y aplicando el conocimiento adquirido.

- **Experiencia Personal:**

Cada etapa del curso representó un desafío y un aprendizaje. Desde las primeras clases hasta los proyectos finales, tuve la oportunidad de experimentar el potencial de la IA de manera práctica. A través de ejercicios, trabajos en equipo y el desarrollo del proyecto, pudimos enfrentar y superar dificultades técnicas, lo que nos brindó una gran satisfacción tanto en lo personal como en lo grupal. Este curso ha consolidado nuestras habilidades en IA y nos ha dado la confianza para aplicarlas en el ámbito laboral y en proyectos futuros. También consolidó una amistad internacional, que perdurará más allá del espacio y el tiempo.

- **Impacto en la Industria o Sociedad:**

La inteligencia artificial tiene el potencial de transformar industrias enteras y la sociedad en general. Este proyecto puede tener un impacto positivo en sectores como la agricultura, haciendo productos más sustentables y aumentando la producción; la salud, al permitir diagnósticos más rápidos y precisos; en la educación, facilitando el acceso a contenidos personalizados; y en la industria, optimizando la producción y reduciendo costos. Creo firmemente que el conocimiento adquirido en este curso contribuirá a que podamos utilizar la tecnología de manera ética y responsable, generando soluciones que mejoren la calidad de vida y aumenten la eficiencia en diferentes sectores.

- **Agradecimientos Especiales:**

**Sandra:**

Quiero expresar mi agradecimiento a la UTN, BOUNTY EDTECH, POSITIVO BGH, e INTEL, por creer en nosotras e invertir en nuestro aprendizaje. Su apoyo ha

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



sido fundamental para que podamos acceder a una formación de calidad en una disciplina tan innovadora como la inteligencia artificial.

Además, agradezco a los profesores y mentores que, con su experiencia y dedicación, nos guiaron en cada etapa del curso y nos inspiraron a explorar nuevos caminos en el mundo de la tecnología.

Finalmente, no quiero dejar de expresar mi agradecimiento y cariño especial al equipo de trabajo, FLOR, MARIA y JOHANA, sin el apoyo constante de todas, no hubiera sido posible finalizar el curso y consolidar los conocimientos adquiridos. Se que esta amistad surgida del curso perdurará a lo largo del tiempo.

GRACIAS GRACIAS GRACIAS A TOD@S! y FELICES FIESTAS!

## Flor:

😊 Quisiera expresar mi más profundo y sincero agradecimiento a todo el equipo del proyecto M1000IA. Estas semanas han sido muy enriquecedoras y transformadoras, no me imaginé llegar tan lejos, crecer tanto.

En primer lugar, agradezco a los profes que compartieron sus conocimientos de una manera sencilla, detallada y alegre. Su orientación y estímulo, su paciencia y calma, nos motivaron a explorar nuevos conceptos y desarrollar nuestras habilidades en inteligencia artificial sin desesperarnos porque nos costaban o no salían las cosas a la primera. Cada clase fue una oportunidad para aprender y crecer, y su pasión por el tema fue contagiosa.

También quiero agradecer a las personas de gestión y acompañamiento, que han trabajado arduamente detrás de escena para que este proyecto fuera posible. Su organización y planificación meticulosas han asegurado un entorno de aprendizaje genial para todas nosotras, así como su disposición para ayudarnos y guiarnos por este camino de aprendizaje.

Gracias a todos por crear este espacio colaborativo y enriquecedor donde pudimos compartir ideas, aprender juntas y construir relaciones duraderas. Estoy emocionada por llevar conmigo todo lo que he aprendido y por seguir explorando el mundo de la IA.

También quiero agradecer a mis coequipers: Sandra, una genia, re expresiva, buenísima redactando; María super atenta, activa en el código y explicando sus avances; y Johana colaborando en todo lo que haga falta. Gracias a este equipo super activo, colaborativo y entusiasta pudimos aprender, compartir y desarrollar un proyecto que alcanzó nuestras expectativas como MVP.  
¡¡¡MUCHAS GRACIAS!!!

# PROGRAMA M1000IA

Sé parte de la Próxima Generación  
Innovadora de la Fuerza de Trabajo Futura



**Johanna:**

No tengo más qué un profundo agradecimiento por la oportunidad de participar en el curso de Inteligencia Artificial para mujeres tecnólogas sin experiencia. Me siento honrada de haber sido seleccionada para esta iniciativa y profundamente inspirada por el compromiso que demuestran al fomentar la inclusión y el acceso al conocimiento en una de las áreas más transformadoras de la tecnología.

Apreciar su esfuerzo por abrir espacios de formación inclusiva y empoderar a mujeres en el ámbito de la tecnología resulta altamente motivador. Estoy convencida de que esta experiencia no solo marcará una diferencia significativa en mi desarrollo profesional, sino que también tendrá un impacto positivo en mi confianza y en las metas que me proponga alcanzar en esta carrera.

Gracias a iniciativas como esta, muchas mujeres tenemos la posibilidad de adentrarnos en el mundo de la Inteligencia Artificial y soñar con un futuro donde podamos aportar con seguridad y talento en este campo.

También quiero agradecer a mis compañeras de equipo, es un orgullo haber compartido este logro con ustedes, GRACIAS por el esfuerzo, compromiso y dedicación que cada una de ustedes puso para hacer posible la entrega del proyecto. Gracias por su entrega y por no rendirse frente a los desafíos que encontramos. Su disposición para colaborar, resolver problemas y aportar con ideas innovadoras no solo fue clave para el éxito del proyecto, sino que también hizo que todo el proceso fuera enriquecedor y motivador. ¡Felicitaciones a todas por el excelente trabajo!